

改进奖励函数的深度强化学习路径规划方法

桑 焱 马晓宁

(中国民航大学计算机科学与技术学院 天津 300300)

摘 要 针对深度强化学习在路径规划问题中的稀疏奖励问题,提出一种基于潜能奖励函数的深度强化学习模型。该模型通过设计新的奖励函数,提高奖励密度和样本利用率,减少训练难度,提升智能体在不同地图中的寻路成功率。仿真结果表明,改进后的模型在简单地图上路径规划成功率提高 7.08 个百分点,在复杂地图上规划成功率提高 12.60 个百分点;与最先进的算法对比,寻路成功率近似,但规划路径结果的长度较短。

关键词 深度强化学习 路径规划 移动机器人 奖励函数

中图分类号 TP391.9

文献标志码 A

DOI:10.3969/j.issn.1000-386x.2025.01.038

PATH PLANNING METHOD OF DEEP REINFORCEMENT LEARNING WITH IMPROVED REWARD FUNCTION

Sang Yao Ma Xiaoning

(College of Computer Science and Technology, Civil Aviation University of China, Tianjin 300300, China)

Abstract Aimed at the sparse reward problem of deep reinforcement learning in path planning, a deep reinforcement learning model based on potential reward function is proposed. By designing a new reward function, the model improved the reward density and sample utilization, reduced the difficulty of training, and improved the success rate of agent in different maps. The simulation results show that the path planning success rate of the improved model is improved by 7.08 percentage points on simple maps and 12.60 percentage points on complex maps. Compared with the most advanced algorithms, the routing success rate is similar, but the length of the planned path result is shortened.

Keywords Deep reinforcement learning Path planning Mobile robots Reward function

0 引 言

随着计算机技术的不断提高,移动机器人的智能化程度也在不断地提高,路径规划技术是移动机器人核心技术之一而备受关注^[1]。移动机器人路径规划的目的是寻找一条从机器人当前位置到达目标位置的路径,该路径应该满足无碰撞、距离尽可能短等特征^[2]。路径规划算法是路径规划技术的核心,常用的传统路径规划算法有人工势场法^[3]、遗传算法^[4]、A*(A-Star)及其改进算法^[5]和智能仿生算法^[6]等,但是这些方法都需要对环境建模,且模型精度会对算法性能产生一定影响。因此,无需建模的强化学习被广泛应用于路径通用规划领域^[7-9]和特殊路径规划领域,例如船舶

航线规划^[10]、无人艇的路径规划^[11-12]等。

强化学习是一种无模型的机器学习方法,通过智能体与环境交互并获得奖励,通过最大化累计奖励来优化策略,代表算法为 Q-Learning 算法。该算法通过建立 Q 值表评估当前状态下每个动作的价值,经过多次迭代更新后, Q 值表会趋于收敛,从中选取对应价值最高的动作,即为最优的行动策略。强化学习算法通过随机化搜索策略在一定程度上解决算法陷入局部最优的问题,但在复杂环境下,会遇到维数灾难问题,很难训练。Mnih 等^[13]提出了深度 Q 网络(Deep Q Net, DQN)模型,使用深度神经网络替换 Q-Learning 算法中用于估计动作的价值的 Q 值表,解决了复杂环境下的 Q 值表维度过大,而难以训练的问题,并在一些雅达利游戏中取得了高于普通人类的分数。

收稿日期:2021-09-13。基于人工智能的互联网医疗服务信息质量评价方法研究项目(2019KJ127)。桑焱,硕士生,主研领域:深度强化学习。马晓宁,副教授。

强化学习算法的一个重要组成部分是奖励函数,智能体需要奖励函数来获取环境给予的反馈,通常奖励函数的设计与任务密切相关,且有时设定较差的奖励函数会使智能体学习到意想不到的行为^[14]。强化学习算法与深度强化学习算法在路径规划领域中得到了广泛的应用^[9-11],但是在这些文献中,仅在模拟回合结束后给予奖励,奖励较为稀疏,样本利用率较低,智能体缺乏足够的反馈,使算法更易收敛于局部最优,无法获得更优的解。

为了强化学习方法应用于路径规划问题中存在的奖励稀疏问题,本文结合人工势场法和基于潜能的奖励函数设计法,提出了基于潜能的双竞争 Q 网络模型(Potential Based Dueling DQN, PB-DuelingDQN),提高了样本的利用率,并提高了智能体在复杂环境下的寻路成功率,且通过仿真实验验证了提出模型的性能。

1 相关理论

1.1 基于值的强化学习

强化学习是一种将环境状态映射到动作的学习,学习目标是使智能体从环境中获取到最大的累计奖励,该方法可以基于马尔可夫决策过程(Markov Decision Process, MDP)建模^[18]。定义四元组 (S, A, G, f) , 其中:

1) S 为环境状态的集合, $s_t \in S$ 表示智能体位于 t 时刻的状态;

2) A 为智能体动作的集合, $a_t \in A$ 表示智能体位于 t 时刻选择的动作;

3) $G: S \times A \rightarrow R$, 为奖励函数, $r_t \sim G(s_t, a_t)$ 表示智能体在第 t 时刻选择动作 a_t 获得的奖励值;

4) $f: S \times A \times S \rightarrow p \in [0, 1]$ 为状态转移概率分布函数, $s_{t+1} \sim f(s_t, a_t)$ 表示智能体在状态 s_t 下, 选择动作 a_t 并转移到下一状态 s_{t+1} 的概率。

强化学习的最终目的是使智能体学到一个根据环境信息指导行动的策略 $\pi: S \rightarrow A$, 并使用评估指标奖励 R 评估不同策略之间的优劣, 定义为:

$$R = \sum_{t=0}^T \gamma^t r_t \quad (1)$$

式中: $\gamma \in (0, 1]$ 是衰减因子, 用于表示未来奖励对累计奖励的影响。

状态动作价值函数 $Q^\pi(s, a)$ 表示智能体在一轮模拟中始终遵循策略 π 所获得累计回报的期望, 如式(2)所示。

$$Q^\pi(s, a) = E[R | s_t, a_t, \pi] \quad (2)$$

如果存在一个策略 π^* 的状态动作价值函数大于等于其他所有策略的状态动作价值函数, 则称此策略为最佳策略, 最佳策略可以有多个, 但是最佳状态动作价值函数只有一个, 为:

$$Q^*(s, a) = \max_{\pi} E[R | s_t, a_t, \pi] \quad (3)$$

由于 $Q^*(s, a)$ 遵循贝尔曼最优方程, 即:

$$Q^*(s, a) = E[r + \gamma \max_{a'} Q(s', a') | s, a] \quad (4)$$

所以可以通过迭代求解 Q 函数, 即:

$$Q_{i+1}(s, a) = E[r + \gamma \max_{a'} Q_i(s', a') | s, a] \quad (5)$$

当 $i \rightarrow \infty$ 时, Q 函数趋近于最优 Q 函数, 从而可以获得最优策略 π^* 。

$$\pi^* = \operatorname{argmax}_{a \in A} Q^*(s, a) \quad (6)$$

在复杂应用中, 通过迭代贝尔曼方程求解最优 Q 函数的计算开销较大, 因此常常使用深度神经网络等非线性函数逼近器去拟合值函数。

1.2 稀疏奖励问题

基于值的强化学习算法常使用时间差分误差更新算法参数, 例如在 DQN 算法中, 该误差定义为式(7)。

$$\delta_t^{\text{DQN}} = r_{t+1} + \gamma \max_a Q(s, a) - Q(s, a) \quad (7)$$

由误差定义式(7)可知, 若智能体仅能在模拟回合结束时获得最终奖励, 则会导致大部分样本的误差极低, 在误差函数中的贡献较小, 使模型难以优化, 智能体难以学到最终的最佳策略。因此, 结合具体应用场景, 给予每一步一个即时奖励 $r_{\text{intrinsic}}$, 可以解决强化学习中稀疏奖励问题, 以降低模型的训练难度, 并提升智能体的性能。

2 改进奖励函数的深度强化学习模型

2.1 基于潜能的改进奖励函数设计

强化学习的特点之一是使用奖励信号来形式化最终目的。智能体总是学习如何最大化奖励, 因此, 需要将奖励和实现目的紧密结合。

简单的奖励函数设计通常只在一轮模拟结束时给予奖励, 称为外部奖励, 例如在路径规划问题中, 仅仅在智能体遇到障碍或到达目的地时给予奖励, 奖励信号过于稀疏, 导致最终训练结果不佳^[14]。稀疏奖励问题可以通过向奖励函数中添加即时奖励解决, 但是, 修改奖励函数会产生新的马尔可夫决策过程, 因此, 需要保证修改后的马尔可夫决策过程 M' 的最优策略与原马尔可夫决策过程 M 的最优策略相同。

定义一个重塑奖励函数 $F: S \times A \times S \rightarrow R$, 如果存在即时奖励 $\Phi: S \rightarrow R$, 则称该奖励函数为基于潜能的^[19]。

$$F(s, a, s') = \gamma \Phi(s') - \Phi(s) \quad (8)$$

使用基于潜能的奖励函数构造的新马尔可夫过程 M' 可以保证与原马尔可夫过程 M 的最优策略相同^[19]。结合先验知识添加基于潜能的即时奖励,可以提高模拟样本的利用率,指导智能体学习到更优的策略。例如考虑路径规划问题的特点,可以选择智能体与目标位置的欧几里得距离作为即时奖励,即:

$$\Phi(s) = d_s = (x_{\text{dest}} - x_s)^2 + (y_{\text{dest}} - y_s)^2 \quad (9)$$

因此,可以构建新的奖励函数为:

$$G(s_{t+1}, a_t, s_t) = \begin{cases} r_{\text{Extrinsic}} & s_{t+1} = \text{dest} \\ -r_{\text{Extrinsic}} & s_{t+1} = \text{block} \\ d_{s_{t+1}} - d_{s_t} & \text{其他} \end{cases} \quad (10)$$

当智能体到达终点时,奖励为正外部奖励,当智能体与障碍物发生碰撞时,奖励为负外部奖励,其余情况下均给予即时奖励,为了防止外部奖励信号被即时奖励信号淹没,外部奖励的大小通常与问题的规模相关。

2.2 改进奖励函数的双竞争 Q 网络模型

深度强化学习模型使用深度神经网络去拟合值函数,令深度神经网络参数为 θ ,则有:

$$Q(s, a; \theta) \approx Q^*(s, a) \quad (11)$$

深度强化学习模型自提出之后,发展出多种算法模型,深度双 Q 网络(Double DQN, DDQN)^[20]模型使用目标网络和估计网络解决了 DQN 模型中的过估计问题,竞争 Q 网络(Dueling DQN)^[21]模型进一步将值函数分为两部分,即:

$$Q(s, a; \theta, \alpha, \beta) = V(s) + A(s, a) \quad (12)$$

其中 $V(s)$ 、 $A(s, a)$ 为:

$$V(s) = V(s; \theta, \beta) \quad (13)$$

$$A(s, a) = A(s, a; \theta, \alpha) - \frac{1}{|A|} \sum_a A(s, a'; \theta, \alpha) \quad (14)$$

式中: θ 为深度神经网络参数, $V(s)$ 为状态价值函数, β 为其参数,含义为当前状态 s 的价值; $A(s, a)$ 为状态-动作价值函数, α 为其参数,含义为在当前状态下,采取动作 a 的优势,即在状态 s 下采取动作 a 的回报与在状态 s 下平均回报的差值。本文将改进后的奖励函数与竞争 Q 网络模型结合,并同时使用目标网络和估计网络解决过估计问题,提出基于潜能的竞争 Q 网络模型,即构建两个网络竞争 Q 网络参数组:估计网络(θ, α, β)和目标网络($\theta^-, \alpha^-, \beta^-$)。若令 $a' = \arg\max_a Q(s, a; \theta, \alpha, \beta)$, 则优化目标 y_i 为:

$$y_i = r + \gamma Q(s_{t+1}, a'; \theta^-, \alpha^-, \beta^-) \quad (15)$$


算法流程如算法 1 所示。

算法 1 PB-Dueling DQN 算法

1. 初始化大小为 N 的双向队列为记忆重放区 M , 估计网络参数 θ , 目标网络参数 θ^- , 折扣因子 γ , 探索因子 ε , 学习率 α , 批处理量 BatchSize , 回合结束标识 $\text{Done} = \text{false}$
2. for episode = 1 to N do;
3. 初始化环境状态 s
4. while $s \neq s_{\text{end}}$ do;
5. 根据 ε -greedy 策略选择动作 a
6. 智能体执行动作 a , 状态转移为 s_{t+1} , 根据式计算奖励值
7. 将 $(s_t, s_{t+1}, a, r, \text{Done})$ 存入 M
8. 从 M 中取 BatchSize 个样本
9. 根据梯度下降法, 根据 $(y_i - Q(s_t, a; \theta, \alpha, \beta))^2$ 更新网络参数
10. 更新网络参数
11. 每经过 c 步, 同步参数 $\theta^- = \theta$
12. end while
13. end for

3 基于潜能的双竞争 Q 网络模型的路径规划算法

本节使用前文提出的基于潜能的双竞争 Q 网络模型强化学习算法构建路径规划算法, 算法输入为栅格地图, 输出为智能体动作。本文构建了如图 1 所示的二维栅格仿真环境, 其中每个栅格的尺寸为 1×1 , 为四联通, 即智能体仅能选择上、下、左、右四种动作。地图根据复杂程度分为两类, 简单环境和复杂环境。简单环境大小为 16×16 , 障碍物个数为 32; 复杂环境大小为 28×28 , 障碍物个数为 171。两类地图中寻路起点方格均不固定, 而寻路终点方格设置固定为右下角方格。简单环境中包含 43 607 幅训练地图和 10 963 幅测试地图, 复杂环境中包含 126 056 幅训练地图和 31 511 幅测试地图。



(a) 简单环境

(b) 复杂环境

图 1 栅格地图

算法需要在训练地图中对智能体进行训练, 根据式设计训练过程中所需的奖励函数如式(16)所示, 其中 $d_s = (x_{\text{dest}} - x_s)^2 + (y_{\text{dest}} - y_s)^2$, x, y 分别为智能体当前位置的横坐标和纵坐标。

$$G(s_{t+1}, a_t, s_t) = \begin{cases} 10 & s_{t+1} = dest \\ -10 & s_{t+1} = block \\ d_{s_{t+1}} - d_{s_t} & \text{其他} \end{cases} \quad (16)$$

4 实验结果与分析

4.1 仿真环境和参数设置

本文进行三组对比实验,第一组实验验证新奖励函数对路径规划效果的提升,即对比 PB-Dueling DQN 算法与 Dueling DQN 算法。第二组实验验证算法的有效性,即对比 PB-Dueling DQN 算法模型与基线算法:DDQN^[20]和 DQN^[13]算法,这两种算法及其改进常用于路径规划领域^[7-9, 11-12],第三组实验验证算法性能上的优越性,即对比 PB-Dueling DQN 算法和最先进算法:SAC-Discrete 算法^[22],三组实验的实验环境相同,均在二维栅格仿真环境上进行,且选取路径规划成功率和平均成功寻路长度作为评价指标。

实验环境操作系统为 Ubuntu 18. 04, GPU 为 Nvidia RTX 2080 Ti,神经网络框架为 PyTorch 1. 8. 1,且使用 Python 3. 8. 0 编程实现。

第一组实验算法网络模型有五层,输入层为路径规划地图,输出层为智能体的值函数,维度为 4,即智能体可采取动作的个数,若输入地图长宽为 (h, w) ,则隐藏层设置如表 1 所示,超参数设置如表 2 所示,且探索因子 ε 最小值为 0. 1。

表 1 隐藏层设置

隐藏层	输入维度	输出维度
卷积层 1	$(3, h, w)$	$(32, h, w)$
平均池化层	$(32, h, w)$	$(32, h/2, w/2)$
卷积层 2	$(32, h/2, w/2)$	$(64, h/2, w/2)$
平均池化层	$(64, h/2, w/2)$	$(64, h/4, w/4)$
卷积层 3	$(64, h/4, w/4)$	$(64, h/4, w/4)$
平均池化层	$(64, h/4, w/4)$	$(64, 1, 1)$

表 2 超参数设置

参数	值
学习率 α	0. 000 25
探索因子 ε	0. 999 997 5 $\times \varepsilon$
折扣因子 γ	$\gamma_{16} = 0. 9, \gamma_{28} = 0. 99$
目标网络更新频率	300
经验回放区大小	1 $\times 10^6$
批处理量	256

4.2 实验结果与对比分析

图 2、图 3 分别为双竞争 Q 网络模型和改进奖励函数方法在简单环境和复杂环境下训练过程的奖励曲线。通过对比可知,两种方法在收敛速度上无明显差距,但 PB-Dueling DQN 在收敛后获得的奖励更高,表明可以学到更好的策略。在测试集上对两方法性能进行验证,测试结果如表 3 和表 4 所示。




图 2 简单环境奖励曲线




图 3 复杂环境奖励曲线

表 3 实验一寻路成功率(%)

环境大小	PB-Dueling DQN	Dueling DQN
16 $\times$ 16	87. 01	79. 93
28 $\times$ 28	62. 92	50. 32

表 4 实验一平均成功寻路长度

环境大小	PB-Dueling DQN	Dueling DQN
16 $\times$ 16	14. 94	15. 18
28 $\times$ 28	24. 22	25. 72

由表 3 可知,PB-Dueling DQN 算法在随机生成的简单环境下和复杂环境下,对陌生测试地图的寻路成功率均有所提升,在简单环境下,提升率为 7. 08 百分点;在复杂环境下,提升率 12. 60 百分点,表明 PB-Dueling DQN 与 Dueling DQN 相比,能更好地在易变的环境中完成任务。表 4 为两种算法的平均成功寻路长

度,PB-Dueling DQN 相对于 Dueling DQN 方法在平均寻路长度上也相对较短。

图 4、图 5 为 DDQN 算法和 DQN 算法在复杂环境下的奖励曲线,与图 2、图 3 类似,PB-Dueling DQN 算法与 DQN 和 DDQN 算法在收敛速度上无明显差别,在 PB-Dueling DQN 算法收敛后,奖励值较高。表 5、表 6 也表明 PB-Dueling DQN 算法在成功寻路长度上更优。




图 4 DQN 复杂环境奖励曲线




图 5 DDQN 复杂环境奖励曲线

表 5 实验二寻路成功率(%)

环境大小	PB-Dueling DQN	DDQN	DQN
16 × 16	87.01	75.62	69.70
28 × 28	62.92	59.02	53.95

表 6 实验二平均成功寻路长度

环境大小	PB-Dueling DQN	DDQN	DQN
16 × 16	14.94	15.78	16.12
28 × 28	24.22	26.15	26.37

通过实验发现,相较于 DQN 及其变式算法,PB-Dueling DQN 算法在没有明显增加训练难度的情况下,提升了算法在陌生地图上的寻路成功率且成功寻路长度更短,表明改进后的算法可以更好地指导智能体学习,可以有效地缓解了原算法中遇到的稀疏奖励问题。

图 6、图 7 为 SAC-Discrete 与 PB-Dueling DQN 算

法在相同环境下的奖励函数曲线,SAC-Discrete 算法收敛较快,但是收敛后的奖励值较低,这是因为 SAC-Discrete 算法具有易陷入局部最优的缺点,表 7、表 8 为 SAC-Discrete 算法与 PB-Dueling DQN 算法的寻路成功率和平均成功寻路长度,通过对比,SAC 算法在寻路成功率上与 PB-Dueling DQN 算法无较大差距,但是在成功寻路长度上,SAC 算法劣于其余所有算法,可能原因是算法陷入了局部最优值。




图 6 SAC-Discrete 简单环境奖励函数曲线




图 7 SAC-Discrete 复杂环境奖励曲线

表 7 SAC-Discrete 寻路成功率(%)

环境大小	PB-Dueling DQN	SAC-Discrete
16 × 16	87.01	84.96
28 × 28	62.92	59.71

表 8 SAC-Discrete 平均成功寻路长度

环境大小	PB-Dueling DQN	SAC-Discrete
16 × 16	14.94	20.56
28 × 28	24.22	34.14

5 结 语

本文以自寻路机器人在栅格地图上的路径规划为研究背景,针对传统深度强化学习在研究背景下存在奖励稀疏,训练较为困难,且容易陷入局部最优等问题,提出了一种基于潜能的奖励函数,并根据改进的奖励函数,提出了改进后的 PB-Dueling DQN 算法,通过

改进后的奖励函数可以更好地对寻路策略进行优化,避免陷入局部最优,有效地提高了机器人的寻路成功率,并减少了规划结果中的多余动作。实验表明,PB-Dueling DQN 算法具有较优的性能。

但是,在 PB-Dueling DQN 的训练超参数设置问题仍有待研究,例如:折扣因子的选取会影响智能体对不同时间步的奖励敏感度,从而影响训练过程中的稳定性;学习率参数会影响到算法在训练过程中的收敛时间,若学习率过高则可能导致算法收敛于局部最优。因此,下一步的研究目标是寻找 BP-Dueling DQN 算法的最优超参数组合,使算法性能最优。

参 考 文 献

- [1] 吴正,赵怀林. 基于改进 A* 算法和 lattice 算法的路径规划方法[J]. 计算机应用与软件, 2021, 38(6): 288 - 293, 305.
- [2] 徐晓苏,袁杰. 基于改进强化学习的移动机器人路径规划方法[J]. 中国惯性技术学报, 2019, 27(3): 314 - 320.
- [3] 赵明,郑泽宇,么庆丰,等. 基于改进人工势场法的移动机器人路径规划方法[J]. 计算机应用研究, 2020, 37(S2): 66 - 68, 72.
- [4] 谢永盛,曾箫箫,冯文健. 改进布谷鸟搜索算法在多机器人任务分配及路径规划中的应用[J]. 计算机应用与软件, 2021, 38(2): 285 - 290.
- [5] 赵卫东,蒋超. 两阶段搜索的 A* 全局路径规划算法[J]. 计算机应用与软件, 2020, 37(12): 249 - 253.
- [6] 蒋美云. 基于初始路径封闭区域的机器人路径规划算法[J]. 计算机应用与软件, 2020, 37(9): 263 - 267, 301.
- [7] 李婷. 基于强化学习的路径规划算法研究[D]. 长春: 吉林大学, 2020.
- [8] 吴夏铭. 基于深度强化学习的路径规划算法研究[D]. 长春: 长春理工大学, 2020.
- [9] 尹旷,王红斌,方健,等. 基于强化学习的移动机器人路径规划优化[J]. 电子测量技术, 2021, 44(10): 91 - 95.
- [10] 刘抚楷. 基于深度强化学习的船舶路径规划方法研究[D]. 武汉: 武汉理工大学, 2020.
- [11] 王亭. 基于强化学习的无人艇路径规划方法与设计[D]. 哈尔滨: 哈尔滨工程大学, 2020.
- [12] 随博文,黄志坚,姜宝祥,等. 基于深度 Q 网络的水面无人艇路径规划算法[J]. 上海海事大学学报, 2020, 41(3): 1 - 5, 116.
- [13] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529 - 533.
- [14] 杨惟轶,白辰甲,蔡超,等. 深度强化学习中稀疏奖励问题研究综述[J]. 计算机科学, 2020, 47(3): 182 - 191.
- [15] 毛国君,顾世民. 改进的 Q-Learning 算法及其在路径规划中的应用[J]. 太原理工大学学报, 2021, 52(1): 91 - 97.
- [16] 李辉,祁宇明. 一种复杂环境下基于深度强化学习的机器人路径规划方法[J]. 计算机应用研究, 2020, 37(S1): 129 - 131.
- [17] 黄东晋,蒋晨凤,韩凯丽. 基于深度强化学习的三维路径规划算法[J]. 计算机工程与应用, 2020, 56(15): 30 - 36.
- [18] 刘全,翟建伟,章宗长,等. 深度强化学习综述[J]. 计算机学报, 2018, 41(1): 1 - 27.
- [19] Harutyunyan A, Devlin S, Vrancx P, et al. Expressing arbitrary reward functions as potential-based advice[C]//AAAI Conference on Artificial Intelligence, 2015: 2652 - 2658.
- [20] Hasselt H, Guez A, Silver D. Deep reinforcement learning with double Q-learning[C]//AAAI Conference on Artificial Intelligence, 2016: 2094 - 2100.
- [21] Wang Z Y, Schaul T, Hessel M, et al. Dueling network architectures for deep reinforcement learning[C]//33rd International Conference on Machine Learning, 2016: 1995 - 2003.
- [22] Haarnoja T, Zhou A, Abbeel P, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor[C]//International Conference on Machine Learning, 2018: 1861 - 1870.

(上接第 263 页)

- [9] 余翀,邱其文. 基于栅格地图的分层式机器人路径规划算法[J]. 中国科学院大学学报, 2013, 30(4): 528 - 538, 546.
- [10] 陈若男,文聪聪,彭玲,等. 改进 A* 算法在机器人室内路径规划中的应用[J]. 计算机应用, 2019, 39(4): 1006 - 1011.
- [11] 张凡,蔡涛,刘文达,等. 基于改进 JPS 算法的电站巡检机器人路径规划[J]. 电子测量技术, 2020, 43(8): 10 - 16.
- [12] 王杰. 跳点搜索算法 JPS 及其优化[EB/OL]. [2022 - 06 - 25]. <https://runzhiwang.github.io/2019/06/21/jps/#more>.
- [13] Harabor D, Grastien A. The JPS pathfinding system[C]//5th Annual Symposium on Combinatorial Search, 2012: 207 - 208.
- [14] Wei X S, Wang X Y, Chen S Y. Research on parameterization and optimization procedure of low-Reynolds-number airfoils based on genetic algorithm and Bezier curve[J]. Advances in Engineering Software, 2020, 149: 102864.
- [15] Li Z, Mei X S. Navigation and control system of mobile robot based on ROS[C]//3rd Advanced Information Technology, Electronic and Automation Control Conference, 2018: 368 - 372.
- [16] Oajsalee S, Tantrairatn S, Khaengkarn S. Study of ROS based localization and mapping for closed area survey[C]//5th International Conference on Mechatronics System and Robots, 2019: 24 - 28.
- [17] 李金良,舒翰儒,刘德建,等. 基于改进 RRT 路径规划算法[J]. 组合机床与自动化加工技术, 2021, 4(2): 22 - 24, 29.